
# 神经网络算法推导全过程

### 一. 二元 logistic 回归

假设现在有m个样本 $(x_i, y_i)$ ,每个样板的维度为n。

#### 逻辑回归模型



00010070707070

### 1.1 前向传播推导过程

(1) 
$$X = \begin{bmatrix} x_1^1 & \dots & x_m^1 \\ \dots & \dots & \dots \\ x_1^n & \dots & x_m^n \end{bmatrix}$$
,  $Y = [y_1, \dots, y_m]$ 

(2) 
$$\mathbf{z} = \mathbf{w}^T \mathbf{x} + \mathbf{b}$$
,  $\mathbf{w} = \begin{bmatrix} w_1 \\ \dots \\ w_n \end{bmatrix}$ ,  $\mathbf{b} = \mathbf{w}_0$ 

(3) 
$$\hat{y} = \frac{1}{1 + e^{-z}}$$
,  $\hat{y}$ 为预测值,  $Loss(w,b) = -(ylog(\hat{y}) + (1-y)log(1-\hat{y})$ 

(4) 代价函数 
$$J(w,b) = -\frac{1}{m} \sum_{i=1}^{m} y_i \log(\hat{y}_i) + (1-y_i) \log(1-\hat{y}_i)$$


### 1.2 反向传播过程推导

利用微积分原理,初始化w,b。然后利用导数和随机梯度下降算法不断求取最优解。

(3)最后,通过循环多次,不断更新 w 和 b 求取最优解。

# 二. 人工神经网络

假设现在有m个样本 $(x_i, y_i)$ ,每个样板的维度为n。



# 2.1 人工神经网络前向传播

(1) 
$$\mathbf{X} = \begin{bmatrix} x_1^1 & \dots & x_m^1 \\ \dots & \dots & \dots \\ x_1^n & \dots & x_m^n \end{bmatrix}$$
 ,  $\mathbf{Y} = [y_1, \dots, y_m]$ 

(2)

#### 隐藏层前向传播过程

隐藏层激活函数: 
$$\theta^{[1]}(z) = \tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}$$

$$z_1^{[1]} = w_1^{[1]}x + b_1^{[1]}, a_1^{[1]} = \theta^{[1]}(z_1^{[1]}),$$

$$z_2^{[1]} = w_2^{[1]}x + b_2^{[1]}, a_2^{[1]} = \theta^{[1]}(z_2^{[1]})$$
...
$$z_l^{[1]} = w_l^{[1]}x + b_l^{[1]}, a_l^{[1]} = \theta^{[1]}(z_l^{[1]})$$
向量化表示:  $z^{[1]} = w^{[1]}x + b^{[1]}, a^{[1]} = \theta^{[1]}(z^{[1]})$ 

$$w_{(l,n)}, z_{(l,m)}, b_{(l,1)}, a_{(l,m)}$$

#### 输出层前向传播过程

输出层激活函数: 
$$f(z) = sigmoid(z) = \frac{1}{1 + e^{-z}}$$

$$z^{[2]} = w^{[2]}a^{[1]} + b^{[2]}, a^{[2]} = sigmoid(z^{[2]})$$

$$w^{[2]}_{(1,l)}, z^{[2]}$$

$$\hat{y} = a^{[2]}$$

#### 整理如下

$$z^{[1]} = w^{[1]}x + b^{[1]}$$

$$a^{[1]} = \theta^{[1]}(z^{[1]})$$

$$z^{[2]} = w^{[2]}a^{[1]} + b^{[2]}$$

$$a^{[2]} = \theta^{[2]}(z^{[2]})$$

#### (3) 损失函数

$$Cost(w,b) = -\frac{1}{m} \sum_{i=1}^{m} y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)$$

### 2.2 人工神经网络反向传播

利用微积分原理,初始化 w, b。然后利用链式求导法和随机梯度下降算法不断求取最优解。 (1)输出层通过误差反向传播更新权重

$$\begin{split} \mathrm{dw}^{[2]} &= \frac{\partial J(w^{[2]}, b^{[2]}, w^{[1]}, b^{[1]})}{\partial w^{[2]}}, \mathrm{db}^{[2]} = \frac{\partial J(w^{[2]}, b^{[2]}, w^{[1]}, b^{[1]})}{\partial b^{[2]}} \\ \mathrm{w}^{[2]} &= w^{[2]} - \alpha dw^{[2]}, dw^{[2]} = (\widehat{y} - y) * z^{[2]} \\ b^{[2]} &= b^{[2]} - \alpha db^{[2]}, db[2] = (\widehat{y} - y) \\ \\ \not\exists \mathbb{E} m \land \not \downarrow & \\ \mathrm{w}^{[2]} &= w^{[2]} - a \frac{1}{m} \sum_{i=1}^{m} (\widehat{y}_i - y_i) * a_i^{[1]} \\ b^{[2]} &= b^{[2]} - a \frac{1}{m} \sum_{i=1}^{m} (\widehat{y}_i - y_i) \end{split}$$

(2) 隐藏层通过误差反向传播更新权重

 $b^{[1]} = b^{[1]} - a \frac{1}{m} \sum_{i=1}^{m} (\hat{y}_i - y_i) w^{[2]^T} * \frac{\partial \theta^{[1]}}{\partial z^{[1]}}$ 

$$\begin{split} z^{[1]} &= w^{[1]}x + b^{[1]}, z^{[1]}$$
维度: $(l,m), w^{[1]}$ 维度: $(l,m)$  
$$a^{[1]} &= \theta^{[1]}(z^{[1]}), \theta^{[1]} = \frac{e^z - e^{-z}}{e^z + e^{-z}}, a^{[1]}$$
维度: $(l,m)$  
$$z^{[2]} &= w^{[2]}a^{[1]} + b^{[2]}, z^{[2]}$$
维度: $(1,l), w^{[2]}$ 维度: $(1,l)$  
$$a^{[2]} &= \theta^{[2]}(z^{[2]}), \theta^{[2]} = \frac{1}{1 + e^{-z}},$$
维度: $(1,l)$  
$$\hat{y} &= a^{[2]} \\ J(w^{[2]}, b^{[2]}, w^{[1]}, b^{[1]}) &= -\frac{1}{m} \sum_{i=1}^{m} y_i \log \hat{y}_i + (1 - y_i) \log(1 - \hat{y}_i) \\ \frac{\partial J}{\partial w^{[1]}} &= dw^{[1]} = \frac{\hat{y}_i - y_i}{(1 - \hat{y}_i)\hat{y}_i} * (1 - \hat{y}_i)\hat{y}_i * w^{[2]} * \frac{\partial \theta^{[1]}}{\partial z_i^{[1]}} * x_i = (\hat{y}_i - y_i)w^{[2]^T} * \frac{\partial \theta^{[1]}}{\partial z} * x_i^T \\ \frac{\partial J}{\partial b^{[1]}} &= db^{[1]} = \frac{\hat{y}_i - y_i}{(1 - \hat{y}_i)\hat{y}_i} * (1 - \hat{y}_i)\hat{y}_i * w^{[2]} * \frac{\partial \theta^{[1]}}{\partial z_i^{[1]}} = (\hat{y}_i - y_i)w^{[2]^T} * \frac{\partial \theta^{[1]}}{\partial z} \\ * \mathcal{B} \mathcal{B} n \wedge \mathring{\mathcal{H}} \mathring{\Phi} \end{split}$$